Fleury NIYOKWIZERA



Informations personnelles

Fleury NIYOKWIZERA

fleuryniyokwizera2021@gmail.com

+33 7 45 51 42 89

2 Rue du Maire Becquart
59160 Lille

fleury-fcn.github.io

linkedin.com/in/fleuryniyokwizera

github.com/fleury-fcn

Compétences

Python

pandas

PySpark

Django REST

SQL

PostgreSQL

Oracle

Environnement Cloud : GCP

Bash

pipelines ETL/ELT

synchronisation de bases de données

traitement de données massives et en temps réel

modélisation de données

Profil

Data Engineer (Master Modélisation des Données, Université de Lille), j'ai conçu, déployé et maintenu en production deux plateformes open source de données (Halal Open Food Facts et Halal Open Beauty Facts), de l'ingestion de plus de 4,5 millions de produits jusqu'à l'infrastructure auto-hébergée. Je maîtrise Python, SQL/PostgreSQL, PySpark, Docker et l'automatisation de pipelines, et j'intègre aujourd'hui des agents IA (LLM, RAG) aux données. Je recherche une alternance ou un stage en Data Engineering à partir de Novembre 2026.

Formation

Master 1, Modélisation des Données — **2026 - 2027**
Université de Lille, France

Master 2, Statistique Appliquée et Informatique Décisionnelle — **2025 - 2026**
ISTA, Université du Burundi

- mémoire en cours de finalisation

Master 1, Statistique Appliquée et Informatique Décisionnelle — **2024 - 2025**
ISTA, Université du Burundi

Licence en Actuariat, spécialisation Analyse des Risques — **2021 - 2024**
ISTA, Université du Burundi

Expérience professionnelle

Chief Engineer bénévole, plateformes open source — **oct. 2025 - juin 2026**
Halal Open Food Facts & Halal Open Beauty Facts (halalopenfoodfacts.org, halalopenbeautyfacts.org), Lille

- Conçu l'architecture et développé deux plateformes de données open source en production (Django REST, PostgreSQL, Docker, Redis/Celery), ouvertes au public : **4 500 000 produits référencés, 12 000 visiteurs/mois, 350 contributeurs inscrits.**
- Migré l'infrastructure vers un VPS OVHcloud et automatisé l'import et la synchronisation de plus de 4,5 millions de produits : **durée de synchronisation réduite de 9 h à 55 min, soit -90 %, et 25 000 tâches Celery traitées par jour.**
- Sécurisé l'infrastructure (HTTPS, sauvegardes, accès restreints) et instauré un processus de contribution open source (CI, documentation, gouvernance du code) : **40 pull requests fusionnées, 99,5 % de disponibilité, temps de réponse API médian < 300 ms.**

Assistant consultant, suivi et évaluation de projet — **févr. 2025 - juin 2025**
Projet UMWUGA N'AKAZI (CREOPS, BBIN, WHH), Burundi

- Collecté et analysé des données de terrain avec KoboToolbox ; produit des indicateurs et des rapports statistiques pour le suivi du projet : **1 200 ménages enquêtés, 45 indicateurs suivis, 6 rapports trimestriels.**
- Automatisé le nettoyage et la consolidation des données : **temps de**

files de tâches Redis/Celery

PostgreSQL

Oracle

NoSQL

Redis

Docker

Linux

VPS OVHcloud

Nginx

Git/GitHub

CI (GitHub Actions)

intégration de LLM via API

agents IA conversationnels

RAG et bases vectorielles (pgvector)

scikit-learn

modèles prédictifs

validation croisée

Power BI

Streamlit

KoboToolbox

Langues

Français C2

Anglais C2

Centres d'intérêt

- Jeux d' Échecs
- contribution à des projets open source
- lecture d'ouvrages techniques

préparation des rapports réduit de 3 jours à 4 h.

Stagiaire, Data Science appliquée à l'assurance **juil. 2024 - oct. 2024**

SOCAR Vie, Burundi

- Étudié et prototypé l'intégration de l'IA dans le processus de tarification en assurance vie : **jeu de 50 000 contrats, modèle de gradient boosting, erreur de prédiction réduite de 12 % par rapport au modèle de référence.**
- Présenté les résultats à la direction technique : **1 restitution, recommandations adoptées pour la phase pilote.**

Activités extra-professionnelles

Agent IA conversationnel pour plateformes web **ce jour**

Halal Open Food Facts et Halal Open Beauty Facts

- Conception et intégration d'un agent IA (LLM) pour assister les utilisateurs et faciliter l'interrogation des données produits : **4,5 M de produits interrogeables en langage naturel, réponse en moins de 3 s, précision de 85 % sur un jeu de 200 questions test.**
- Stack : Python, API LLM, RAG avec pgvector, PostgreSQL.

Pipeline Big Data, NYC Yellow Taxi

- Pipeline PySpark de traitement de données à grande échelle, quatre modèles de machine learning et tableau de bord interactif Streamlit : 40 millions de courses traitées, temps de traitement divisé par 6 vs pandas, meilleur modèle $R^2 = 0,87$.
- Stack : PySpark, Parquet, scikit-learn, Streamlit.

Prédiction de sinistres en assurance, Machine Learning

- Pipeline ML modulaire avec recherche d'hyperparamètres, validation croisée et configuration des jeux de données : 5 modèles comparés, validation croisée à 5 plis, AUC = 0,81 pour le meilleur modèle.
- Stack : Python, scikit-learn, pandas.

OpenISTA, plateforme de gestion universitaire

- Application Flask/PostgreSQL : gestion des étudiants, enseignants, cours, bibliothèque et messagerie.

Documents Assist, application IA documentaire

- agent IA conversationnel permettant d'explorer des documents et de les interroger en langage naturel, à partir des documents enregistrés dans l'application comme ressources.
- Technologies : modèle de langage (LLM) open source Mistral et base vectorielle pgvector.
- Code disponible sur GitHub.